Deteksi Gegenpressing Menggunakan Temporal Graph Neural Network pada Data Tracking IDSSE

Rizal Andi Pranata
Program Studi Teknik Informatika, Institut Asia Malang
Naskah penelitian • hasil final per 23 Oktober 2026

Abstrak

Penelitian ini mengembangkan dan mengevaluasi pipeline untuk mendeteksi gegenpressing setelah kehilangan penguasaan bola menggunakan data posisi dan event IDSSE. Sebanyak 2.353 kandidat transisi diperiksa; 1.873 episode memenuhi kriteria valid ketat. Dari 264 episode yang dipilih untuk anotasi, seluruhnya telah memperoleh label biner: 222 gegenpressing dan 42 bukan gegenpressing. Episode direpresentasikan sebagai urutan graph selama empat detik, dari dua detik sebelum sampai dua detik sesudah kehilangan bola, pada 25 Hz. Model Temporal GNN yang menggabungkan dua lapisan Graph Convolutional Network dan GRU dibandingkan dengan logistic regression serta XGBoost melalui pembagian data berdasarkan pertandingan. Pada 40 sampel uji dari satu pertandingan, Temporal GNN memperoleh F1 0,870 dan recall 0,938, sedangkan XGBoost memperoleh average precision tertinggi, yaitu 0,906. Logistic regression menghasilkan precision tertinggi, yaitu 0,839. Hasil menunjukkan pertukaran kinerja antarmodel, bukan keunggulan yang konsisten dari satu model. Karena test hanya mencakup satu pertandingan dan delapan contoh negatif, temuan ini dibatasi sebagai proof of concept dan belum dapat digeneralisasikan ke pertandingan profesional secara luas.

Kata kunci: gegenpressing; counterpressing; tracking sepak bola; graph neural network; IDSSE

Abstract

This study develops and evaluates a pipeline for detecting gegenpressing after possession loss using IDSSE positional and event data. Of 2,353 transition candidates, 1,873 episodes met strict structural validity criteria. All 264 selected episodes received binary annotations: 222 positive and 42 negative. Each episode was represented as a four-second graph sequence spanning two seconds before and after possession loss at 25 Hz. A Temporal GNN combining two Graph Convolutional Network layers with a GRU was compared with logistic regression and XGBoost using match-level splits. On 40 test episodes from one match, the Temporal GNN achieved an F1 score of 0.870 and recall of 0.938, while XGBoost achieved the highest average precision at 0.906. Logistic regression had the highest precision at 0.839. The results show metric trade-offs rather than consistent superiority of one model. Because the test set contains a single match and only eight negative examples, findings should be treated as a proof of concept and cannot yet be generalized to professional football more broadly.

Keywords: gegenpressing; counterpressing; soccer tracking; graph neural network; IDSSE

I Pendahuluan

Kehilangan penguasaan bola memulai fase transisi bertahan yang menuntut keputusan cepat. Tim dapat menekan lawan segera setelah kehilangan bola atau lebih dahulu kembali ke struktur bertahan. Gegenpressing—atau counterpressing—merujuk pada upaya menekan pada fase tersebut. Pengenalannya dari data membutuhkan pembacaan perubahan posisi, kecepatan mendekati bola, hubungan antarpemain, serta konteks waktu. Penelitian terdahulu menunjukkan bahwa transisi bertahan dapat dipelajari sebagai tugas klasifikasi terawasi berbasis data posisi dan event [3].

Label perilaku perlu dibedakan dari hasil perebutan kembali bola. Tim dapat melakukan tekanan tanpa berhasil merebut bola, sementara regain dapat terjadi karena kesalahan lawan tanpa tekanan yang jelas. Karena itu, penelitian ini menggunakan anotasi perilaku sebagai target deteksi. Keberhasilan regain dalam lima detik disimpan sebagai outcome terpisah dan tidak menjadi fitur maupun label model.

IDSSE menyediakan event dan tracking tersinkronisasi dari tujuh pertandingan liga Jerman [1], [2]. Data tersebut memungkinkan pembentukan episode transisi dan representasi relasional antarpemain. Berbeda dari fitur tabular yang merangkum tekanan, graph dapat mempertahankan hubungan lokal pada tiap frame dan urutan perubahan sepanjang episode. Penelitian ini menguji apakah pipeline tersebut dapat dilatih dan dievaluasi dengan pembagian pertandingan yang konsisten.

Pertanyaan penelitian adalah: (1) bagaimana membentuk episode kehilangan bola yang konsisten dari IDSSE; dan (2) bagaimana hasil Temporal GNN dibandingkan dengan logistic regression dan XGBoost pada split pertandingan yang sama? Tujuan penelitian adalah membangun pipeline yang dapat diaudit dan melaporkan hasil uji dengan batas interpretasi yang jelas. Perbandingan yang tersedia menilai gabungan representasi dan model; penelitian ini belum mengisolasi kontribusi graph atau komponen temporal melalui ablasi.

II Tinjauan Pustaka

Deteksi counterpressing

Bauer dan Anzer mengembangkan deteksi counterpressing profesional dengan label manual dan fitur yang dirancang bersama pengetahuan analis sepak bola [3]. Studi tersebut menjadi rujukan untuk memisahkan perilaku tekanan dari outcome transisi. Fitur baseline dalam penelitian ini lebih ringkas dan disesuaikan dengan implementasi lokal, sehingga perbandingan angka dengan studi terdahulu tidak dilakukan langsung.

Tracking IDSSE dan graph temporal

IDSSE memuat informasi pertandingan, event, serta koordinat pemain dan bola dari tujuh pertandingan resmi Bundesliga dan 2. Bundesliga; dataset diterbitkan terbuka dengan lisensi CC BY 4.0 [1], [2]. Graph Convolutional Network mengagregasi informasi fitur node melalui struktur hubungan lokal [4]. GRU memodelkan urutan menggunakan keadaan tersembunyi dan mekanisme gerbang [5]. Pada penelitian ini, pemain dan bola menjadi node, sedangkan kedekatan posisi membentuk graph per frame. Hubungan tersebut merupakan representasi komputasional, bukan klaim bahwa suatu interaksi taktis benar-benar terjadi.

Model pembanding dan ruang lingkup VAEP

Logistic regression menyediakan pembanding linear, sementara XGBoost memodelkan pola nonlinier melalui boosting pohon [6], [7]. Kedua model menggunakan 12 fitur tekanan. Temporal GNN menggunakan urutan graph dengan konteks waktu yang lebih lengkap. VAEP menilai aksi melalui perubahan probabilitas mencetak dan kebobolan gol [8], tetapi pemetaan event dan validasi model probabilitas VAEP belum menjadi bagian eksperimen ini. Oleh karena itu, hasil penelitian hanya membahas deteksi gegenpressing, bukan nilai atau efektivitas aksi.

III Metode

Rancangan dan data

Penelitian menggunakan eksperimen komputasional kuantitatif dan supervised learning. Unit analisis adalah episode kehilangan bola. Data utama berasal dari IDSSE, yang menyediakan event dan tracking pemain serta bola pada frekuensi 25 Hz [1]. Manifest lokal memuat 2.353 kandidat perubahan penguasaan bola ketika bola hidup. Kandidat kemudian diaudit berdasarkan kelengkapan window, kontinuitas frame, interval waktu, validitas koordinat, dan roster 11 lawan 11. Sebanyak 1.873 episode (79,60%) lolos kriteria valid ketat.

Pemilihan episode dan anotasi

Antrean anotasi mencakup paling banyak 40 episode per pertandingan, dengan 24 episode untuk J03WN1 karena keterbatasan kandidat yang memenuhi kriteria. Sampling awal menyeimbangkan outcome quick regain dan menjaga jarak waktu minimal dua detik pada periode yang sama. Karena sampling terkait outcome tersebut, distribusi label antrean tidak dapat dianggap sebagai prevalensi alami gegenpressing. Peneliti memberi label 1 untuk gegenpressing dan 0 untuk bukan gegenpressing. Audit final menyatakan seluruh 264 episode memiliki label biner dan layak digunakan; tidak ada label ragu yang masuk ke training.

Keputusan anotasi dibantu tampilan tracking pada lima titik waktu setelah turnover dan indikator tekanan. Anotasi berasal dari satu penilai utama; kesepakatan antarpenilai independen belum dihitung. Karena indikator yang terlihat dalam tampilan sebagian sejalan dengan fitur baseline, kemungkinan anchoring terhadap indikator tersebut tetap menjadi keterbatasan. Hasil audit final menunjukkan tidak ada label berstatus keyakinan rendah, tetapi hal ini tidak menggantikan pengukuran reliabilitas antarpenilai.

Pembentukan episode dan representasi graph

Setiap episode mencakup rentang −2 sampai +2 detik relatif terhadap kehilangan bola. Pada 25 Hz, rentang inklusif ini terdiri atas 101 frame. Setiap frame memiliki 23 node: 22 pemain dan bola. Enam fitur node memuat koordinat x dan y, kecepatan, indikator bola, serta indikator keanggotaan pada tim yang kehilangan dan memperoleh bola. Graph menghubungkan tetangga terdekat dalam tiap frame dan menghasilkan 92 edge terarah. Model memakai dua lapisan GCN dengan 32 unit, pooling node per frame, GRU 32 unit, dropout 0,2, dan kepala klasifikasi biner. Fitur kontinu dinormalisasi dengan statistik data train saja.

Baseline, split, dan evaluasi

Logistic regression menggunakan imputasi median, standardisasi, dan bobot kelas seimbang. XGBoost memakai 200 pohon, kedalaman maksimum 3, learning rate 0,05, subsampling 0,8, serta pembobotan sampel. Fitur baseline terdiri atas 12 indikator kedekatan, jumlah penekan, laju pendekatan, durasi tekanan, dan kekompakan. Quick regain tidak termasuk fitur. Pembagian dilakukan per pertandingan: lima pertandingan untuk train, J03WQQ untuk validation, dan J03WPY untuk test. Split ini menjaga agar episode dari pertandingan yang sama tidak tersebar lintas set.

Jumlah sampel adalah 184 train, 40 validation, dan 40 test. Ambang klasifikasi tiap model dipilih dengan memaksimalkan F1 pada validation dan kemudian dikunci untuk test. Evaluasi melaporkan accuracy, precision, recall, F1, ROC-AUC, average precision (AP), dan confusion matrix. Pelatihan menggunakan random seed 42. Temporal GNN dilatih dengan AdamW, batch 8, dan penghentian dini berdasarkan loss validation; model terbaik dicapai pada epoch ke-21 dari 36 epoch yang berjalan.

IV Hasil dan Pembahasan

Kualitas data dan distribusi label

Dari 2.353 kandidat, 1.873 memenuhi validitas ketat dan 264 episode dipilih sebagai antrean anotasi. Audit final memastikan semua 264 label biner dapat digunakan: 222 positif (84,09%) dan 42 negatif (15,91%). Proporsi positif yang tinggi mencerminkan komposisi sampel yang tersedia, termasuk prosedur pemilihan berdasarkan outcome regain; angka ini tidak boleh ditafsirkan sebagai frekuensi gegenpressing pada seluruh pertandingan.

Tabel 1. Jumlah sampel dan distribusi kelas pada split pertandingan.

Split	Pertandingan	Jumlah	Positif	Negatif
Train	5	184	157	27
Validation	1	40	33	7
Test	1	40	32	8
Total	7	264	222	42

Kinerja pada pertandingan uji

Pada split test, Temporal GNN menghasilkan F1 tertinggi (0,870) dan recall tertinggi (0,938). XGBoost memperoleh average precision tertinggi (0,906), sedangkan logistic regression memperoleh precision tertinggi (0,839). Temporal GNN mendeteksi 30 dari 32 contoh positif, tetapi menandai tujuh dari delapan contoh negatif sebagai positif pada ambang terpilih. XGBoost menandai seluruh delapan contoh negatif sebagai positif. Logistic regression lebih konservatif, dengan lima false positive dan enam false negative. Dengan demikian, nilai F1 dan recall Temporal GNN yang tinggi muncul bersama jumlah false positive yang lebih besar.

Tabel 2. Kinerja pada 40 sampel test; ambang dipilih pada validation.

Model	Ambang	Precision	Recall	F1	ROC-AUC	AP	TN/FP/FN/TP
Logistic regression	0,313	0,839	0,813	0,825	0,551	0,851	3/5/6/26
XGBoost	0,256	0,778	0,875	0,824	0,668	0,906	0/8/4/28
Temporal GNN	0,300	0,811	0,938	0,870	0,676	0,866	1/7/2/30

ROC-AUC Temporal GNN (0,676) sedikit lebih tinggi daripada XGBoost (0,668), sementara nilai logistic regression adalah 0,551. Perbedaan tersebut perlu ditafsirkan hati-hati: set uji hanya berisi satu pertandingan dan delapan contoh negatif. AP dipengaruhi prevalensi positif yang tinggi, yaitu 32/40 pada test; karena itu, nilai AP tidak berdiri sebagai ukuran generalisasi lintas pertandingan. Tidak dilakukan uji signifikansi atau interval kepercayaan karena satu pertandingan uji tidak menyediakan replikasi pertandingan yang memadai.

Batas interpretasi

Hasil menunjukkan bahwa Temporal GNN memiliki trade-off yang menarik pada split uji, khususnya recall dan F1, tetapi belum membuktikan keunggulan umum atas baseline. XGBoost tetap menghasilkan AP tertinggi, dan precision logistic regression paling tinggi. Uji hanya menggunakan satu pertandingan test (J03WPY) dari total tujuh pertandingan. Performa dapat berubah pada pertandingan, tim, atau kondisi lain. Hasil belum cukup untuk klaim generalisasi ke sepak bola profesional secara luas.

Model menggunakan dua detik observasi setelah kehilangan bola. Dengan demikian, tugas yang diuji adalah deteksi retrospektif dari respons yang telah mulai terlihat, bukan prediksi instan tepat ketika bola hilang. Konstruksi graph menggunakan koordinat tracking yang telah dinormalisasi, sedangkan sejumlah fitur baseline dinyatakan dalam meter; perbedaan ruang ini perlu diselaraskan atau dievaluasi melalui eksperimen sensitivitas sebelum perbandingan kausal terhadap representasi graph dilakukan. Penelitian ini juga belum menguji ablasi GCN tanpa GRU, model tanpa konteks sebelum turnover, atau evaluasi leave-one-match-out.

Keterbatasan lain mencakup satu penilai utama, distribusi kelas yang tidak seimbang, antrean sampel yang dikondisikan oleh outcome quick regain, kemungkinan episode berdekatan memiliki konteks yang tumpang tindih, dan cakupan data yang hanya tujuh pertandingan. Penelitian lanjutan perlu menambah pertandingan, melibatkan anotator independen, mengukur kesepakatan label, menyelaraskan fitur input baseline dan GNN, serta mengulang evaluasi pada beberapa pertandingan yang tidak digunakan dalam training. Analisis VAEP baru relevan setelah skema aksi dan probabilitas gol divalidasi.

V Simpulan

Penelitian ini membangun pipeline deteksi gegenpressing berbasis tracking IDSSE dan mengevaluasi Temporal GNN bersama logistic regression serta XGBoost. Dari 2.353 kandidat transisi, 1.873 lolos validasi ketat. Sebanyak 264 episode dianotasi dan seluruhnya memiliki label biner, terdiri atas 222 positif dan 42 negatif. Representasi temporal menggunakan 101 frame, 23 node, dan enam fitur node per episode.

Pada 40 sampel uji dari satu pertandingan, Temporal GNN memperoleh F1 0,870 dan recall 0,938; XGBoost memperoleh AP tertinggi 0,906; dan logistic regression memiliki precision tertinggi 0,839. Temuan ini memperlihatkan pertukaran kinerja antar-model dan belum menetapkan model yang unggul secara umum. Ukuran test yang kecil, satu pertandingan uji, ketimpangan kelas, serta tidak adanya reliabilitas antarpenilai membatasi kesimpulan sebagai proof of concept. Evaluasi lintas banyak pertandingan dan audit anotasi independen diperlukan sebelum menyimpulkan generalisasi atau manfaat operasional.

Daftar Pustaka

[1] M. Bassek, R. Rein, H. Weber, dan D. Memmert, “An integrated dataset of spatiotemporal and event data in elite soccer,” Scientific Data, vol. 12, artikel 195, 2025. https://doi.org/10.1038/s41597-025-04505-y

[2] M. Bassek, R. Rein, H. Weber, dan D. Memmert, An integrated dataset of spatiotemporal and event data in elite soccer, Figshare, versi 1, 2025. https://doi.org/10.6084/m9.figshare.28196177.v1

[3] P. Bauer dan G. Anzer, “Data-driven detection of counterpressing in professional football,” Data Mining and Knowledge Discovery, vol. 35, hlm. 2009–2049, 2021. https://doi.org/10.1007/s10618-021-00763-7

[4] T. N. Kipf dan M. Welling, “Semi-supervised classification with graph convolutional networks,” International Conference on Learning Representations, 2017. https://arxiv.org/abs/1609.02907

[5] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, dan Y. Bengio, “Learning phrase representations using RNN encoder–decoder for statistical machine translation,” Proceedings of EMNLP, hlm. 1724–1734, 2014. https://doi.org/10.3115/v1/D14-1179

[6] T. Chen dan C. Guestrin, “XGBoost: A scalable tree boosting system,” Proceedings of the 22nd ACM SIGKDD Conference on Knowledge Discovery and Data Mining, hlm. 785–794, 2016. https://doi.org/10.1145/2939672.2939785

[7] F. Pedregosa et al., “Scikit-learn: Machine learning in Python,” Journal of Machine Learning Research, vol. 12, hlm. 2825–2830, 2011. https://www.jmlr.org/papers/v12/pedregosa11a.html

[8] T. Decroos, L. Bransen, J. Van Haaren, dan J. Davis, “Actions speak louder than goals: Valuing player actions in soccer,” Proceedings of the 25th ACM SIGKDD Conference on Knowledge Discovery and Data Mining, hlm. 1851–1861, 2019. https://doi.org/10.1145/3292500.3330758