Pengembangan Temporal Graph Neural Network untuk Deteksi Gegenpressing pada Data Spatiotemporal IDSSE

Rizal Andi Pranata
Program Studi Teknik Informatika, Institut Asia Malang

Bagian II Tinjauan Pustaka

Cakupan hasil hingga 19 Oktober 2026

II Tinjauan Pustaka

Deteksi counterpressing berbasis data

Bauer dan Anzer [3] mengembangkan deteksi counterpressing menggunakan data posisi dan event, label manual, serta 134 fitur berbasis pengetahuan pakar. Penelitian tersebut menunjukkan peran pembelajaran terawasi dan model XGBoost dalam identifikasi transisi. Baseline pada penelitian ini menggunakan 12 fitur tekanan yang tersedia dalam implementasi lokal. Dengan demikian, baseline tersebut merupakan pembanding yang disesuaikan dengan ruang lingkup data, bukan replikasi seluruh fitur dan prosedur studi terdahulu. Perbedaan dataset, pedoman anotasi, dan pembagian data juga membuat angka performa antarpublikasi tidak dapat dibandingkan langsung.

Dataset posisi dan representasi graph

Bassek et al. [1] memperkenalkan IDSSE yang mencakup dua pertandingan Bundesliga dan lima pertandingan divisi kedua musim 2022/2023. Berkas aslinya terdiri atas informasi pertandingan, event, dan posisi dalam format XML. Data posisi dikumpulkan melalui sistem optik TRACAB Gen5 pada 25 Hz. Dataset tersedia dengan lisensi CC BY 4.0 [2], sedangkan video pertandingan tidak disertakan. Cakupan tujuh pertandingan mendukung pengembangan metode awal, tetapi membatasi interpretasi hasil untuk populasi pertandingan yang lebih luas.

GCN menggabungkan fitur simpul dengan informasi struktur graph melalui agregasi dari lingkungan lokal [4]. Untuk kasus ini, simpul mewakili pemain dan bola, sedangkan edge dibentuk menurut kedekatan posisi. Edge tersebut merupakan keputusan representasi yang disusun peneliti; keberadaannya tidak menyatakan bahwa umpan, tekel, atau tekanan benar-benar terjadi. Makna terhadap target gegenpressing dipelajari melalui hubungan antara representasi episode dan label acuan.

Pemodelan urutan dan model pembanding

GRU menggunakan mekanisme gerbang untuk mengatur pembaruan keadaan tersembunyi pada data berurutan [5]. Pada arsitektur yang dikembangkan, keluaran GCN diringkas menjadi vektor per frame sebelum diproses GRU. Istilah temporal merujuk pada pemanfaatan urutan frame tersebut, sehingga model mempertimbangkan perubahan situasi selama episode, bukan hanya konfigurasi satu frame.

Logistic regression digunakan sebagai pembanding linear pada log-odds probabilitas kelas, dengan implementasi scikit-learn [7]. XGBoost merupakan sistem gradient boosting berbasis pohon yang memodelkan hubungan nonlinier melalui penambahan pohon secara bertahap [6]. Kedua model menerima fitur tekanan yang sama, sementara GNN menerima graph berurutan. Perbandingan utama karena itu menilai pendekatan representasi beserta

modelnya; eksperimen ablasi diperlukan untuk mengisolasi manfaat graph atau komponen temporal secara terpisah.

Deteksi perilaku dan analisis efektivitas

VAEP atau Valuing Actions by Estimating Probabilities menilai aksi melalui perubahan probabilitas mencetak dan kebobolan gol dengan mempertimbangkan konteks keadaan permainan [8]. Kerangka ini menjadi arah pengembangan proyek VAEP-Track setelah deteksi perilaku tersedia. Pada tahap sekarang, pemetaan event IDSSE ke skema aksi dan validasi model probabilitas VAEP belum diselesaikan. Oleh karena itu, hasil artikel ini belum mencakup skor VAEP atau kesimpulan mengenai efektivitas gegenpressing.

Tabel 1 Posisi penelitian terhadap landasan metode

Rujukan	Pokok pendekatan	Hubungan dengan penelitian ini
Bauer dan Anzer [3]	Deteksi counterpressing berlabel manual dan fitur pakar	Dasar target perilaku dan pembanding berbasis fitur
Kipf dan Welling [4] serta Cho et al. [5]	Agregasi lokal graph dan pemodelan urutan	Landasan komponen GCN dan GRU
Chen dan Guestrin [6]	Tree boosting	Landasan pembanding XGBoost
Decroos et al. [8]	Valuasi aksi melalui probabilitas gol	Arah analisis lanjutan yang belum dievaluasi