Pengembangan Temporal Graph Neural Network untuk Deteksi Gegenpressing pada Data Spatiotemporal IDSSE

Rizal Andi Pranata
Program Studi Teknik Informatika, Institut Asia Malang

Bagian III Metode

Cakupan hasil hingga 19 Oktober 2026

III Metode

Rancangan penelitian dan sumber data

Penelitian menggunakan pendekatan kuantitatif dengan eksperimen komputasional komparatif pada data pertandingan sekunder. Tugas utama adalah klasifikasi biner episode menjadi gegenpressing atau bukan gegenpressing melalui supervised learning. Unit analisis adalah episode kehilangan bola; frame dan pemain merupakan komponen dalam episode, bukan sampel penelitian yang berdiri sendiri. Hasil yang tersedia pada tahap ini berupa audit data, statistik anotasi, serta pengujian integrasi implementasi.

Data utama berasal dari IDSSE [1], [2]. Skrip proyek mengakses event dan tracking menggunakan library Kloppy, mengubah keduanya menjadi tabel, lalu menyimpannya sebagai CSV. Versi Kloppy yang diperiksa mengarahkan akses dataset terbuka ke mirror PySport yang merujuk repositori asli Figshare. Pada CSV tracking, satu baris menyatakan satu frame dan kolom menyimpan waktu, status bola, tim pemilik bola, serta koordinat dan kecepatan objek. Identitas pemain dipetakan ke tim melalui catatan event. Pemetaan yang tidak lengkap akan memengaruhi kelolosan audit roster.

Deteksi kehilangan bola dan validasi episode

Kandidat turnover ditentukan ketika identitas tim pemilik bola berubah dalam periode pertandingan yang sama, kedua identitas tersedia, dan kondisi bola memenuhi syarat hidup. Setiap kandidat memiliki identitas unik yang menghubungkan waktu kehilangan bola, pertandingan, tim kehilangan bola, serta tim lawan. Quick regain dalam lima detik dicatat secara terpisah dari label perilaku dan tidak dimasukkan sebagai fitur deteksi.

Window episode ditetapkan dari −2,00 sampai +2,00 detik relatif terhadap kehilangan bola. Frekuensi 25 Hz menghasilkan 100 interval atau 101 frame ketika kedua ujung disertakan. Episode dinyatakan valid ketat apabila window lengkap, nomor frame kontinu, interval waktu 0,04 detik, posisi objek valid, dan terdapat 22 pemain aktif dengan pembagian 11 lawan 11. Kebijakan ini menghasilkan input dengan ukuran seragam, sekaligus membatasi cakupan pada situasi yang memenuhi struktur tersebut.

Pemilihan sampel dan anotasi perilaku

Antrean anotasi dibentuk dari episode valid dengan target paling banyak 40 episode per pertandingan. Sampling menggunakan random seed 42, kuota seimbang menurut outcome quick regain, dan jarak waktu minimal dua detik pada periode yang sama. Keterbatasan kandidat yang memenuhi kuota menghasilkan 24 episode untuk J03WN1 dan 40 episode untuk masing-masing pertandingan lain, sehingga totalnya 264. Keseimbangan outcome tidak menyatakan keseimbangan kelas gegenpressing; distribusi sampel ini juga tidak dapat langsung digunakan untuk mengestimasi prevalensi alami perilaku.

Anotasi dilakukan oleh peneliti menggunakan visualisasi lima cuplikan posisi pada 0; 0,5; 1; 1,5; dan 2 detik setelah turnover serta ringkasan indikator tekanan. Label 1 digunakan untuk gegenpressing, 0 untuk bukan gegenpressing, dan −1 untuk ragu. Setiap keputusan disertai confidence, identitas annotator, dan catatan ketika diperlukan. Label ragu dikeluarkan dari klasifikasi biner hingga peninjauan menghasilkan keputusan yang dapat dipertanggungjawabkan. Anotasi kedua yang independen dan ukuran kesepakatan antarpenilai belum tersedia.

Indikator pendukung mencakup kedekatan terhadap bola, laju mendekat, jumlah penekan, kekompakan lokal, dan durasi tekanan. Konfigurasi saat ini menggunakan radius tekanan dekat 4,572 m, radius pendekatan 10 m, laju mendekat minimal 1 m/s, serta durasi berkelanjutan 0,4 detik. Angka tersebut membantu pembacaan situasi dan bukan aturan otomatis penetapan label. Karena indikator yang ditampilkan juga menjadi bagian fitur baseline, audit independen diperlukan untuk menilai kemungkinan keputusan annotator terlalu mengikuti indikator tersebut.

Representasi graph temporal

Pada setiap frame, graph Gt = (V, Et, Xt) dibentuk dengan 23 node yang mewakili 22 pemain dan bola. Identitas serta urutan node dipertahankan sepanjang episode. Matriks Xt memiliki enam fitur: koordinat x, koordinat y, kecepatan, indikator bola, indikator tim kehilangan bola, dan indikator tim lawan. Bentuk tensor satu episode adalah 101 × 23 × 6. Status indikator tim dihitung relatif terhadap tim yang kehilangan bola pada episode tersebut.

Edge dibentuk secara dinamis dengan menghubungkan setiap node ke empat tetangga terdekat, sehingga konstruksi awal memuat 92 edge terarah per frame. Implementasi menghitung jarak Euclidean pada koordinat ternormalisasi CSV. Karena itu, kedekatan pada graph saat ini tidak dinyatakan sebagai jarak meter. Sebaliknya, indikator anotasi dan baseline menggunakan konversi posisi berdasarkan asumsi lapangan 105 × 68 m. Konsistensi skala dan dimensi lapangan aktual perlu diperiksa sebelum eksperimen akhir karena dapat mengubah urutan tetangga. Model GCN saat ini menerima edge_index tanpa bobot jarak edge secara eksplisit.

Model deteksi dan pembanding

Temporal GNN menggunakan dua lapisan GCN dengan ukuran tersembunyi 32, aktivasi ReLU, dan layer normalization. Masked mean pooling merangkum fitur node menjadi vektor tiap frame. Urutan vektor tersebut diproses GRU berukuran tersembunyi 32, kemudian keadaan terakhir diteruskan melalui dropout 0,2 dan lapisan linear dua kelas. Softmax menghasilkan probabilitas gegenpressing. Normalisasi fitur kontinu x, y, dan kecepatan dipelajari hanya dari train, sedangkan indikator jenis node dan tim tetap biner.

Baseline menggunakan 12 fitur: maksimum jumlah penekan total, penekan langsung, dan pemain yang mendekat; durasi tekanan individual dan kolektif; indikator tekanan berkelanjutan individual dan kolektif; jarak minimum ke bola; laju pendekatan maksimum; maksimum pemain dalam radius 10 m; rerata kekompakan lokal; serta perubahan bentangan tim. Fitur ini dihitung pada respons 0 sampai +2 detik. Perbedaan dengan input GNN yang mencakup −2 sampai +2 detik merupakan bagian rancangan saat ini dan perlu diperhitungkan dalam interpretasi perbandingan.

Tabel 2 Konfigurasi yang tersedia untuk eksperimen akhir

Model	Representasi	Konfigurasi utama

Model	Representasi	Konfigurasi utama
Logistic regression	12 fitur tekanan	Imputasi median, standardisasi, class_weight balanced, maksimum 2.000 iterasi
XGBoost	12 fitur tekanan	200 pohon, max_depth 3, learning_rate 0,05, subsample dan colsample_bytree 0,8, bobot sampel seimbang
Temporal GNN	101 graph per episode	GCN 32 dan 32, GRU 32, dropout 0,2, AdamW, batch 8, maksimum 100 epoch, patience 15

Konfigurasi pada Tabel 2 merupakan pengaturan yang telah disiapkan dalam implementasi dan runner pelatihan akhir, bukan hasil optimasi yang telah membuktikan konfigurasi terbaik. Pelatihan GNN menggunakan cross-entropy berbobot kelas dan pemilihan checkpoint berdasarkan validation loss. Seluruh keputusan pengaturan dan perubahan konfigurasi perlu dicatat sebelum evaluasi akhir.

Pembagian data dan prosedur evaluasi

Pembagian dilakukan menurut pertandingan: J03WMX, J03WN1, J03WOH, J03WOY, dan J03WR9 sebagai train; J03WQQ sebagai validation; serta J03WPY sebagai test. Dengan cara ini, episode dari pertandingan yang sama tidak berada pada split berbeda. Kandidat, label, dan identitas split dibuat konsisten untuk ketiga model. Imputasi dan normalisasi dipelajari dari train. Ambang keputusan tiap model dipilih menggunakan F1 pada validation, lalu digunakan pada test tanpa pemilihan ulang berdasarkan hasil test.

Evaluasi direncanakan menggunakan precision, recall, F1, ROC-AUC, average precision (AP), serta confusion matrix. Precision adalah TP/(TP + FP), recall adalah TP/(TP + FN), dan F1 adalah 2 × precision × recall/(precision + recall). AP merangkum hubungan precision–recall pada berbagai ambang. Implementasi saat ini menyimpan AP dalam kolom bernama pr_auc; artikel menggunakan istilah AP agar tidak menyamakannya dengan integrasi trapezoidal kurva precision–recall. Hasil perlu ditafsirkan bersama jumlah sampel dan distribusi kelas.

Runner membatasi pelatihan final hingga seluruh antrean anotasi diisi, identitas kandidat dan label valid, serta setiap split memiliki sekurang-kurangnya lima contoh untuk masing-masing kelas. Batas lima merupakan pengaman operasional pipeline, bukan pembuktian kecukupan statistik. Snapshot anotasi, konfigurasi, prediksi, dan checksum direncanakan disimpan sebagai artefak reproduksibilitas. Pada progres saat ini, syarat pelatihan akhir belum terpenuhi.