Bagian I Pendahuluan

Pengembangan Temporal Graph Neural Network untuk Deteksi Gegenpressing pada Data Spatiotemporal IDSSE

Rizal Andi Pranata | Program Studi Teknik Informatika, Institut Asia Malang

Cakupan penelitian hingga 19 Oktober 2026

Latar belakang

Transisi setelah kehilangan penguasaan bola merupakan fase penting dalam analisis taktik sepak bola. Respons pemain pada fase ini dapat berupa tekanan segera terhadap penguasaan lawan atau penataan kembali organisasi bertahan. Gegenpressing, yang juga disebut counterpressing, berkaitan dengan respons tekanan setelah kehilangan bola. Identifikasinya memerlukan pembacaan posisi, arah pendekatan, keterlibatan pemain, dan keberlanjutan tekanan dalam rentang waktu singkat. Bauer dan Anzer [3] menempatkan identifikasi perilaku ini sebagai masalah klasifikasi terawasi berdasarkan data posisi dan event.

Perilaku gegenpressing perlu dipisahkan secara operasional dari hasil perebutan kembali penguasaan. Tekanan dapat dilakukan tanpa menghasilkan regain, sementara regain dapat terjadi karena kesalahan lawan. Apabila keberhasilan merebut bola langsung dipakai sebagai label perilaku, model berisiko mempelajari outcome yang berbeda dari tujuan deteksi. Penelitian ini karena itu menggunakan anotasi perilaku sebagai target, sedangkan quick regain dipertahankan sebagai variabel outcome untuk analisis lanjutan.

Data posisi berurutan menyediakan informasi yang relevan untuk menggambarkan hubungan pemain dengan bola dan lawan. IDSSE menyediakan data tersebut bersama catatan event dan informasi pertandingan dalam sumber yang dapat diakses publik [1], [2]. Penggunaannya memungkinkan proses pembentukan episode dan representasi model diperiksa ulang. Namun, akses publik dan kelengkapan koordinat tidak dengan sendirinya menyediakan label gegenpressing atau menjamin kemampuan generalisasi model.

Model berbasis fitur ringkas dapat merangkum jumlah penekan, jarak terhadap bola, dan durasi tekanan. Rangkuman tersebut memudahkan pembelajaran model tabular, tetapi tidak mempertahankan seluruh susunan relasional pada setiap frame. Penelitian ini menguji pendekatan yang menyajikan pemain dan bola sebagai graph berurutan. Graph Convolutional Network (GCN) digunakan untuk mengolah hubungan lokal, sedangkan Gated Recurrent Unit (GRU) digunakan untuk mempelajari perubahan representasi sepanjang episode [4], [5].

Secara operasional, situasi menekan dibaca dari perubahan hubungan pemain yang kehilangan bola terhadap bola dan lawan. Pemain yang sudah dekat pada satu frame belum tentu sedang meningkatkan tekanan, sementara pemain yang semula lebih jauh dapat bergerak cepat mendekati situasi penguasaan. Informasi waktu diperlukan untuk membedakan perubahan tersebut. Graph dipilih sebagai representasi relasional karena identitas pemain dan bola tetap dapat dipertahankan ketika hubungan kedekatannya berubah. Pemilihan representasi ini memiliki alasan konseptual, tetapi efektivitasnya tetap merupakan pertanyaan empiris.

Permasalahan dan pertanyaan penelitian

Permasalahan penelitian mencakup dua tingkat. Tingkat pertama adalah membentuk sampel yang layak dari data tracking, karena kelengkapan window, keterlacakan identitas pemain, dan validitas posisi menentukan apakah graph dapat dibangun secara konsisten. Tingkat

kedua adalah mempelajari perilaku dari sampel berlabel dan mengevaluasi prediksi pada pertandingan berbeda. Keberhasilan menjalankan model tidak cukup untuk menjawab tingkat kedua apabila kualitas label dan jumlah sampel evaluasi masih terbatas.

Pertanyaan penelitian adalah bagaimana membentuk episode transisi IDSSE menjadi graph temporal yang konsisten, bagaimana menyediakan label perilaku yang dapat diaudit, dan apakah pendekatan GCN–GRU memberikan hasil deteksi yang berbeda dari logistic regression serta XGBoost pada pembagian pertandingan yang sama. Hipotesis kerja menyatakan bahwa informasi hubungan spasial dan urutan waktu berpotensi membantu deteksi. Hipotesis tersebut belum dinyatakan terbukti pada tahap penelitian ini.

Pertanyaan tersebut dirumuskan menjadi tiga fokus: pembentukan episode dan graph yang dapat direproduksi; penyediaan label gegenpressing yang terpisah dari outcome serta dapat diaudit; dan perbandingan deteksi menggunakan representasi graph temporal dengan representasi fitur ringkas. Pengamatan perkembangan anotasi merupakan bagian dari penilaian kesiapan eksperimen. Penelitian tidak menetapkan satu model sebagai pemenang sebelum prediksi akhir dibandingkan pada episode evaluasi yang sama.

Tujuan dan kontribusi yang diusulkan

Tujuan penelitian adalah mengembangkan pipeline pengolahan data dan anotasi, mengimplementasikan model deteksi beserta pembanding, dan menyiapkan evaluasi yang dapat direproduksi. Kontribusi yang telah tersedia mencakup manifest episode, representasi graph, perangkat anotasi, dan implementasi pelatihan serta evaluasi. Artikel ini melaporkan hasil pengolahan dan kesiapan eksperimen hingga 19 Oktober 2026. Ruang lingkup kesimpulan dibatasi pada capaian teknis dan kualitas data yang telah diperiksa; analisis efektivitas dan valuasi aksi ditempatkan sebagai pengembangan lanjutan.

Kontribusi yang diusulkan terletak pada keterhubungan definisi target, konstruksi sampel, representasi graph, dan protokol pembanding dalam satu proses yang dapat ditelusuri. Logistic regression memberikan pembanding sederhana, sementara XGBoost memungkinkan pengujian terhadap model nonlinier berbasis fitur. Jika kinerja kedua baseline sudah memadai, kompleksitas tambahan pada Temporal GNN harus dijustifikasi oleh bukti hasil atau karakter kesalahan yang relevan. Karena bentuk inputnya berbeda, evaluasi utama membandingkan pendekatan lengkap dan tidak langsung mengisolasi manfaat satu komponen arsitektur.

Ruang lingkup penelitian

Ruang lingkup mencakup tujuh pertandingan IDSSE dan episode yang memenuhi pemeriksaan struktur. Label perilaku ditentukan melalui visualisasi tracking dan indikator pendukung; video pertandingan tidak digunakan. Pengembangan ini merupakan penelitian awal pada dataset terbatas. Generalisasi lintas kompetisi, penggunaan pada pertandingan dengan kondisi roster berbeda, dan penerapan waktu nyata belum menjadi capaian yang telah diuji.

Proyek diberi nama VAEP-Track sebagai arah pengembangan yang menghubungkan deteksi perilaku dengan analisis efektivitas. Namun, pada cakupan artikel ini, pembahasan utama adalah deteksi gegenpressing dan kesiapan eksperimennya. Penerapan valuasi aksi masih membutuhkan pemetaan event dan pengujian model probabilitas secara terpisah. Pembatasan tersebut menjaga agar pertanyaan penelitian, bukti yang tersedia, dan kesimpulan tetap berada pada lingkup yang sama.

Rujukan bagian ini

[1] M. Bassek, R. Rein, H. Weber, dan D. Memmert, “An integrated dataset of spatiotemporal and event data in elite soccer,” Scientific Data, vol. 12, artikel 195, 2025. https://doi.org/10.1038/s41597-025-04505-y

[2] M. Bassek, R. Rein, H. Weber, dan D. Memmert, “An integrated dataset of spatiotemporal and event data in elite soccer,” Figshare, dataset, versi 1, 2025. https://doi.org/10.6084/m9.figshare.28196177.v1

[3] P. Bauer dan G. Anzer, “Data-driven detection of counterpressing in professional football,” Data Mining and Knowledge Discovery, vol. 35, hlm. 2009–2049, 2021. https://doi.org/10.1007/s10618-021-00763-7

[4] T. N. Kipf dan M. Welling, “Semi-supervised classification with graph convolutional networks,” International Conference on Learning Representations, 2017. https://arxiv.org/abs/1609.02907

[5] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, dan Y. Bengio, “Learning phrase representations using RNN encoder–decoder for statistical machine translation,” Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing, hlm. 1724–1734, 2014. https://doi.org/10.3115/v1/D14-1179