# Bagian II Tinjauan Pustaka

## Pengembangan Temporal Graph Neural Network untuk Deteksi Gegenpressing pada Data Spatiotemporal IDSSE

Rizal Andi Pranata | Program Studi Teknik Informatika, Institut Asia Malang

Cakupan penelitian hingga 19 Oktober 2026

### Deteksi counterpressing berbasis data

Bauer dan Anzer [3] mengembangkan deteksi counterpressing menggunakan data posisi dan event, label manual, serta 134 fitur berbasis pengetahuan pakar. Penelitian tersebut menunjukkan peran pembelajaran terawasi dan model XGBoost dalam identifikasi transisi. Baseline pada penelitian ini menggunakan 12 fitur tekanan yang tersedia dalam implementasi lokal. Dengan demikian, baseline tersebut merupakan pembanding yang disesuaikan dengan ruang lingkup data, bukan replikasi seluruh fitur dan prosedur studi terdahulu. Perbedaan dataset, pedoman anotasi, dan pembagian data juga membuat angka performa antarpublikasi tidak dapat dibandingkan langsung.

Anotasi merupakan penghubung antara konsep taktik dan target statistik yang dipelajari model. Ketika definisi perilaku terlalu bergantung pada keberhasilan regain, target dapat bergeser dari pengenalan tekanan menjadi prediksi outcome. Sebaliknya, definisi yang terlalu longgar dapat menggolongkan setiap kedekatan pemain terhadap bola sebagai gegenpressing. Dalam penelitian ini, persoalan tersebut ditangani melalui pemisahan label perilaku, outcome, dan status ragu, kemudian direncanakan pemeriksaan konsistensi keputusan annotator.

### Dataset posisi dan representasi graph

Bassek et al. [1] memperkenalkan IDSSE yang mencakup dua pertandingan Bundesliga dan lima pertandingan divisi kedua musim 2022/2023. Berkas aslinya terdiri atas informasi pertandingan, event, dan posisi dalam format XML. Data posisi dikumpulkan melalui sistem optik TRACAB Gen5 pada 25 Hz. Dataset tersedia dengan lisensi CC BY 4.0 [2], sedangkan video pertandingan tidak disertakan. Cakupan tujuh pertandingan mendukung pengembangan metode awal, tetapi membatasi interpretasi hasil untuk populasi pertandingan yang lebih luas.

Representasi tabel tracking dan event memiliki unit pencatatan berbeda. Baris tracking menggambarkan posisi objek pada waktu tertentu, sedangkan event menggambarkan kejadian diskret beserta peserta dan atributnya. Pemanfaatan keduanya memerlukan perhatian terhadap waktu, identitas objek, dan sistem koordinat. Pada penelitian ini, tabel tracking menjadi sumber utama perubahan penguasaan dan graph, sedangkan event memberikan konteks serta pemetaan identitas tim. Hasil pengolahan tetap perlu diaudit karena konversi format tidak menghapus keterbatasan sumber data.

GCN menggabungkan fitur simpul dengan informasi struktur graph melalui agregasi dari lingkungan lokal [4]. Untuk kasus ini, simpul mewakili pemain dan bola, sedangkan edge dibentuk menurut kedekatan posisi. Edge tersebut merupakan keputusan representasi yang disusun peneliti; keberadaannya tidak menyatakan bahwa umpan, tekel, atau tekanan benar-benar terjadi. Makna terhadap target gegenpressing dipelajari melalui hubungan antara representasi episode dan label acuan.

Graph dalam pendekatan ini adalah konstruksi yang ditetapkan berdasarkan kebutuhan pemodelan. Pilihan jumlah tetangga, arah edge, fitur node, dan ruang koordinat menentukan informasi yang tersedia bagi model. Hubungan empat tetangga terdekat menyederhanakan

struktur lokal dan membatasi banyaknya koneksi. Konfigurasi tersebut belum dianggap optimal. Apabila hasil eksperimen berubah ketika definisi hubungan diganti, perubahan itu perlu dipahami sebagai sensitivitas representasi, bukan semata-mata perubahan kemampuan belajar model.

### Pemodelan urutan dan model pembanding

GRU menggunakan mekanisme gerbang untuk mengatur pembaruan keadaan tersembunyi pada data berurutan [5]. Pada arsitektur yang dikembangkan, keluaran GCN diringkas menjadi vektor per frame sebelum diproses GRU. Istilah temporal merujuk pada pemanfaatan urutan frame tersebut, sehingga model mempertimbangkan perubahan situasi selama episode, bukan hanya konfigurasi satu frame.

Penggabungan GCN dengan GRU dilakukan pada tingkat representasi frame. Setelah informasi node diringkas, GRU menerima satu vektor untuk setiap waktu pengamatan. Pendekatan ini mempertahankan urutan perubahan keadaan secara global, tetapi pooling juga merangkum detail node. Karena itu, istilah Temporal GNN dalam artikel ini merujuk khusus pada encoder GCN per frame yang diikuti GRU, bukan pada seluruh kemungkinan arsitektur graph dinamis. Pengaruh komponen urutan perlu diuji melalui ablasi jika penelitian hendak mengisolasi manfaat temporal.

Logistic regression digunakan sebagai pembanding linear pada log-odds probabilitas kelas, dengan implementasi scikit-learn [7]. XGBoost merupakan sistem gradient boosting berbasis pohon yang memodelkan hubungan nonlinier melalui penambahan pohon secara bertahap [6]. Kedua model menerima fitur tekanan yang sama, sementara GNN menerima graph berurutan. Perbandingan utama karena itu menilai pendekatan representasi beserta modelnya; eksperimen ablasi diperlukan untuk mengisolasi manfaat graph atau komponen temporal secara terpisah.

Kedua baseline memberikan pembanding dengan representasi yang sama sehingga perbedaan keduanya lebih langsung berkaitan dengan cara mempelajari fitur. Logistic regression memetakan kombinasi fitur ke probabilitas dengan fungsi sigmoid, sedangkan XGBoost membangun interaksi nonlinier melalui pohon. Perbedaan terhadap GNN lebih luas karena mencakup input, konteks waktu, dan arsitektur. Penggunaan split serta target identik diperlukan agar pembandingan tetap dapat ditafsirkan, meskipun tidak menghilangkan semua perbedaan representasi.

### Deteksi perilaku dan analisis efektivitas

VAEP atau Valuing Actions by Estimating Probabilities menilai aksi melalui perubahan probabilitas mencetak dan kebobolan gol dengan mempertimbangkan konteks keadaan permainan [8]. Kerangka ini menjadi arah pengembangan proyek VAEP-Track setelah deteksi perilaku tersedia. Pada tahap sekarang, pemetaan event IDSSE ke skema aksi dan validasi model probabilitas VAEP belum diselesaikan. Oleh karena itu, hasil artikel ini belum mencakup skor VAEP atau kesimpulan mengenai efektivitas gegenpressing.

### Sintesis pustaka dan posisi penelitian

Landasan pustaka mendukung tiga keputusan penelitian: menggunakan label perilaku yang terpisah dari outcome, menyusun representasi relasional dari data posisi, dan mengevaluasi model dengan pembanding yang jelas. Kontribusi penelitian dinilai melalui penerapan serta pengujian keputusan tersebut pada IDSSE. Telaah ini tidak digunakan untuk mengklaim bahwa GCN–GRU adalah pendekatan pertama untuk semua bentuk analisis tekanan atau bahwa kompleksitas model menjamin hasil yang lebih baik.

Tabel 1 Posisi penelitian terhadap landasan metode

| Rujukan | Pokok pendekatan | Hubungan dengan penelitian ini |
|---|---|---|
| Bauer dan Anzer [3] | Deteksi counterpressing berlabel manual dan fitur pakar | Dasar target perilaku dan pembanding berbasis fitur |
| Kipf dan Welling [4] serta Cho et al. [5] | Agregasi lokal graph dan pemodelan urutan | Landasan komponen GCN dan GRU |
| Chen dan Guestrin [6] | Tree boosting | Landasan pembanding XGBoost |
| Decroos et al. [8] | Valuasi aksi melalui probabilitas gol | Arah analisis lanjutan yang belum dievaluasi |

## Rujukan bagian ini


[1] M. Bassek, R. Rein, H. Weber, dan D. Memmert, “An integrated dataset of spatiotemporal and event data in elite soccer,” Scientific Data, vol. 12, artikel 195, 2025. https://doi.org/10.1038/s41597-025-04505-y

[2] M. Bassek, R. Rein, H. Weber, dan D. Memmert, “An integrated dataset of spatiotemporal and event data in elite soccer,” Figshare, dataset, versi 1, 2025. https://doi.org/10.6084/m9.figshare.28196177.v1

[3] P. Bauer dan G. Anzer, “Data-driven detection of counterpressing in professional football,” Data Mining and Knowledge Discovery, vol. 35, hlm. 2009–2049, 2021. https://doi.org/10.1007/s10618-021-00763-7

[4] T. N. Kipf dan M. Welling, “Semi-supervised classification with graph convolutional networks,” International Conference on Learning Representations, 2017. https://arxiv.org/abs/1609.02907

[5] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, dan Y. Bengio, “Learning phrase representations using RNN encoder–decoder for statistical machine translation,” Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing, hlm. 1724–1734, 2014. https://doi.org/10.3115/v1/D14-1179

[6] T. Chen dan C. Guestrin, “XGBoost: A scalable tree boosting system,” Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, hlm. 785–794, 2016. https://doi.org/10.1145/2939672.2939785

[7] F. Pedregosa et al., “Scikit-learn: Machine learning in Python,” Journal of Machine Learning Research, vol. 12, hlm. 2825–2830, 2011. https://www.jmlr.org/papers/v12/pedregosa11a.html

[8] T. Decroos, L. Bransen, J. Van Haaren, dan J. Davis, “Actions speak louder than goals: Valuing player actions in soccer,” Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, hlm. 1851–1861, 2019. https://doi.org/10.1145/3292500.3330758