Bagian III Metode

Pengembangan Temporal Graph Neural Network untuk Deteksi Gegenpressing pada Data Spatiotemporal IDSSE

Rizal Andi Pranata | Program Studi Teknik Informatika, Institut Asia Malang

Cakupan penelitian hingga 19 Oktober 2026

Rancangan penelitian dan sumber data

Penelitian menggunakan pendekatan kuantitatif dengan eksperimen komputasional komparatif pada data pertandingan sekunder. Tugas utama adalah klasifikasi biner episode menjadi gegenpressing atau bukan gegenpressing melalui supervised learning. Unit analisis adalah episode kehilangan bola; frame dan pemain merupakan komponen dalam episode, bukan sampel penelitian yang berdiri sendiri. Hasil yang tersedia pada tahap ini berupa audit data, statistik anotasi, serta pengujian integrasi implementasi.

Tahap penelitian meliputi akuisisi dan pemeriksaan data, pembentukan kandidat dan episode, anotasi, ekstraksi representasi, pengembangan model, serta evaluasi. Tahap pengolahan dan implementasi telah dikerjakan. Anotasi penuh masih berlangsung, sedangkan evaluasi akhir belum dijalankan. Pemisahan status ini digunakan agar prosedur yang telah tersedia dalam kode tidak disajikan seolah-olah telah menghasilkan temuan eksperimen akhir.

Tabel 2 Tahapan penelitian dan keluaran yang diperiksa

Tahap	Keluaran	Pemeriksaan utama
Akuisisi dan konversi	CSV tracking dan event per pertandingan	Identitas pertandingan, waktu, objek, serta kolom yang diperlukan
Pembentukan episode	Manifest kandidat dan validitas	Perubahan penguasaan, 101 frame, posisi valid, dan roster 11 lawan 11
Anotasi	Label perilaku dan confidence	Kelengkapan keputusan, label sah, dan penanganan ragu
Representasi	12 fitur baseline dan sequence graph	Identitas kandidat, ukuran tensor, dan konsistensi fitur
Pelatihan dan evaluasi	Model, prediksi, metrik, serta metadata	Split pertandingan, preprocessing train, dan threshold validation

Data utama berasal dari IDSSE [1], [2]. Skrip proyek mengakses event dan tracking menggunakan library Kloppy, mengubah keduanya menjadi tabel, lalu menyimpannya sebagai CSV. Versi Kloppy yang diperiksa mengarahkan akses dataset terbuka ke mirror PySport yang merujuk repositori asli Figshare. Pada CSV tracking, satu baris menyatakan satu frame dan kolom menyimpan waktu, status bola, tim pemilik bola, serta koordinat dan kecepatan objek. Identitas pemain dipetakan ke tim melalui catatan event. Pemetaan yang tidak lengkap akan memengaruhi kelolosan audit roster.

Satu contoh tracking diidentifikasi melalui kombinasi pertandingan, periode, nomor frame, dan waktu. Kolom pemain menyimpan koordinat x dan y serta kecepatan untuk identitas pemain tertentu. Posisi bola tersimpan terpisah. Pada keluaran Kloppy lokal, koordinat telah berada pada skala ternormalisasi. Metadata sumber dan aturan konversi perlu dicatat untuk

menafsirkan satuan secara konsisten. Nilai posisi kosong diperlakukan sebagai masalah kelengkapan objek dan diperiksa sebelum episode dinyatakan valid.

Deteksi kehilangan bola dan validasi episode

Kandidat turnover ditentukan ketika identitas tim pemilik bola berubah dalam periode pertandingan yang sama, kedua identitas tersedia, dan kondisi bola memenuhi syarat hidup. Setiap kandidat memiliki identitas unik yang menghubungkan waktu kehilangan bola, pertandingan, tim kehilangan bola, serta tim lawan. Quick regain dalam lima detik dicatat secara terpisah dari label perilaku dan tidak dimasukkan sebagai fitur deteksi.

Window episode ditetapkan dari −2,00 sampai +2,00 detik relatif terhadap kehilangan bola. Frekuensi 25 Hz menghasilkan 100 interval atau 101 frame ketika kedua ujung disertakan. Episode dinyatakan valid ketat apabila window lengkap, nomor frame kontinu, interval waktu 0,04 detik, posisi objek valid, dan terdapat 22 pemain aktif dengan pembagian 11 lawan 11. Kebijakan ini menghasilkan input dengan ukuran seragam, sekaligus membatasi cakupan pada situasi yang memenuhi struktur tersebut.

Penggunaan window yang mencakup waktu setelah turnover sesuai dengan tujuan mengenali respons awal terhadap kehilangan bola. Model baru dapat menghasilkan klasifikasi setelah observasi hingga +2 detik tersedia. Episode yang tidak memenuhi syarat tetap tercatat dalam manifest beserta alasan kegagalannya, sehingga penyaringan dapat dianalisis per pertandingan. Syarat jumlah pemain yang tetap juga berarti model saat ini tidak mencakup secara otomatis situasi dengan jumlah pemain berbeda.

Pemilihan sampel dan anotasi perilaku

Antrean anotasi dibentuk dari episode valid dengan target paling banyak 40 episode per pertandingan. Sampling menggunakan random seed 42, kuota seimbang menurut outcome quick regain, dan jarak waktu minimal dua detik pada periode yang sama. Keterbatasan kandidat yang memenuhi kuota menghasilkan 24 episode untuk J03WN1 dan 40 episode untuk masing-masing pertandingan lain, sehingga totalnya 264. Keseimbangan outcome tidak menyatakan keseimbangan kelas gegenpressing; distribusi sampel ini juga tidak dapat langsung digunakan untuk mengestimasi prevalensi alami perilaku.

Pemilihan sampel menggunakan kedua kategori outcome quick regain agar antrean mencakup respons yang diikuti regain dan yang tidak. Penggunaan outcome pada sampling tidak menjadikannya label target. Karena peluang pemilihan dipengaruhi outcome dan validitas struktur, distribusi label hasil anotasi harus dibaca sebagai distribusi sampel penelitian. Jarak minimal dua detik juga belum memastikan independensi penuh karena dua window empat detik dapat berbagi sebagian frame dalam pertandingan yang sama.

Anotasi dilakukan oleh peneliti menggunakan visualisasi lima cuplikan posisi pada 0; 0,5; 1; 1,5; dan 2 detik setelah turnover serta ringkasan indikator tekanan. Label 1 digunakan untuk gegenpressing, 0 untuk bukan gegenpressing, dan −1 untuk ragu. Setiap keputusan disertai confidence, identitas annotator, dan catatan ketika diperlukan. Label ragu dikeluarkan dari klasifikasi biner hingga peninjauan menghasilkan keputusan yang dapat dipertanggungjawabkan. Anotasi kedua yang independen dan ukuran kesepakatan antarpenilai belum tersedia.

Label positif diberikan berdasarkan penilaian adanya respons tekanan segera dari tim yang kehilangan bola, dengan mempertimbangkan hubungan pemain terhadap bola dan perkembangan tekanan pada cuplikan waktu. Label negatif digunakan ketika bukti yang diamati tidak memenuhi interpretasi perilaku tersebut. Status ragu dipertahankan ketika informasi tidak cukup atau indikator saling bertentangan. Kriteria interpretatif ini harus

dipertegas dalam audit pedoman sebelum training final agar konsistensi tidak hanya bergantung pada ingatan annotator.

Panel pengambilan keputusan yang diimplementasikan tidak menampilkan outcome quick regain, tetapi masih menampilkan indikator tekanan dan ringkasan numerik. Karena itu, proses ini tidak dianggap sepenuhnya bebas pengaruh indikator. Peninjauan lanjutan direncanakan dengan penilai independen pada subset sampel, pemisahan keputusan awal, dan pembahasan kasus tidak sepakat. Tingkat keyakinan annotator akan dilaporkan sebagai metadata keputusan, bukan sebagai pengganti pengukuran reliabilitas antarpenilai.

Indikator pendukung mencakup kedekatan terhadap bola, laju mendekat, jumlah penekan, kekompakan lokal, dan durasi tekanan. Konfigurasi saat ini menggunakan radius tekanan dekat 4,572 m, radius pendekatan 10 m, laju mendekat minimal 1 m/s, serta durasi berkelanjutan 0,4 detik. Angka tersebut membantu pembacaan situasi dan bukan aturan otomatis penetapan label. Karena indikator yang ditampilkan juga menjadi bagian fitur baseline, audit independen diperlukan untuk menilai kemungkinan keputusan annotator terlalu mengikuti indikator tersebut.

Representasi graph temporal

Pada setiap frame, graph Gt = (V, Et, Xt) dibentuk dengan 23 node yang mewakili 22 pemain dan bola. Identitas serta urutan node dipertahankan sepanjang episode. Matriks Xt memiliki enam fitur: koordinat x, koordinat y, kecepatan, indikator bola, indikator tim kehilangan bola, dan indikator tim lawan. Bentuk tensor satu episode adalah 101 × 23 × 6. Status indikator tim dihitung relatif terhadap tim yang kehilangan bola pada episode tersebut.

Prosedur pembentukan graph dimulai dengan menentukan roster aktif pada frame kehilangan bola, menyusun urutan identitas node, dan mengambil fitur pada seluruh frame episode. Untuk setiap frame, matriks jarak dihitung dari posisi dua dimensi. Empat tetangga terdekat selain node itu sendiri dipilih sebagai tujuan edge. Daftar edge dihitung ulang pada setiap frame sehingga hubungan dapat berubah ketika objek bergerak. Tensor fitur dan edge kemudian disimpan dengan identitas kandidat yang sama dengan manifest anotasi.

Edge dibentuk secara dinamis dengan menghubungkan setiap node ke empat tetangga terdekat, sehingga konstruksi awal memuat 92 edge terarah per frame. Implementasi menghitung jarak Euclidean pada koordinat ternormalisasi CSV. Karena itu, kedekatan pada graph saat ini tidak dinyatakan sebagai jarak meter. Sebaliknya, indikator anotasi dan baseline menggunakan konversi posisi berdasarkan asumsi lapangan 105 × 68 m. Konsistensi skala dan dimensi lapangan aktual perlu diperiksa sebelum eksperimen akhir karena dapat mengubah urutan tetangga. Model GCN saat ini menerima edge_index tanpa bobot jarak edge secara eksplisit.

Model deteksi dan pembanding

Temporal GNN menggunakan dua lapisan GCN dengan ukuran tersembunyi 32, aktivasi ReLU, dan layer normalization. Masked mean pooling merangkum fitur node menjadi vektor tiap frame. Urutan vektor tersebut diproses GRU berukuran tersembunyi 32, kemudian keadaan terakhir diteruskan melalui dropout 0,2 dan lapisan linear dua kelas. Softmax menghasilkan probabilitas gegenpressing. Normalisasi fitur kontinu x, y, dan kecepatan dipelajari hanya dari train, sedangkan indikator jenis node dan tim tetap biner. Komponen GCN dan GRU menggunakan landasan pemodelan graph dan urutan pada [4] dan [5].

Urutan komputasi model adalah Xt → GCN pertama → GCN kedua → layer normalization → mean pooling node → GRU → dropout → klasifikasi dua kelas. Mask node digunakan pada pooling untuk membatasi kontribusi objek yang valid. Hidden state GRU pada frame terakhir

mewakili episode untuk klasifikasi. Walaupun jarak antarobjek tersedia pada proses konstruksi, implementasi ini belum memasukkan jarak tersebut sebagai bobot edge pada operasi GCN; informasi spasial berasal dari posisi node dan struktur ketetanggaan.

Baseline menggunakan 12 fitur: maksimum jumlah penekan total, penekan langsung, dan pemain yang mendekat; durasi tekanan individual dan kolektif; indikator tekanan berkelanjutan individual dan kolektif; jarak minimum ke bola; laju pendekatan maksimum; maksimum pemain dalam radius 10 m; rerata kekompakan lokal; serta perubahan bentangan tim. Fitur ini dihitung pada respons 0 sampai +2 detik. Perbedaan dengan input GNN yang mencakup −2 sampai +2 detik merupakan bagian rancangan saat ini dan perlu diperhitungkan dalam interpretasi perbandingan. Implementasi model pembanding menggunakan XGBoost [6] dan scikit-learn [7].

Beberapa fitur dapat tidak terdefinisi ketika syarat pengukuran tidak terpenuhi, misalnya kekompakan lokal jika pemain dalam radius lokal terlalu sedikit. Implementasi baseline menggunakan imputasi median dari train, bukan menghapus nilai kosong secara diam-diam atau menghitung imputasi dari seluruh dataset. Logistic regression juga menggunakan standardisasi fitur dari train. Pembobotan kelas diterapkan pada data pelatihan untuk mengurangi dominasi kelas mayoritas, tetapi tidak diperlakukan sebagai solusi terhadap kesalahan label.

Tabel 3 Konfigurasi yang tersedia untuk eksperimen akhir

Model	Representasi	Konfigurasi utama
Logistic regression	12 fitur tekanan	Imputasi median, standardisasi, class_weight balanced, maksimum 2.000 iterasi
XGBoost	12 fitur tekanan	200 pohon, max_depth 3, learning_rate 0,05, subsample dan colsample_bytree 0,8, bobot sampel seimbang
Temporal GNN	101 graph per episode	GCN 32 dan 32, GRU 32, dropout 0,2, AdamW, batch 8, maksimum 100 epoch, patience 15

Konfigurasi pada Tabel 3 merupakan pengaturan yang telah disiapkan dalam implementasi dan runner pelatihan akhir, bukan hasil optimasi yang telah membuktikan konfigurasi terbaik. Pelatihan GNN menggunakan cross-entropy berbobot kelas dan pemilihan checkpoint berdasarkan validation loss. Seluruh keputusan pengaturan dan perubahan konfigurasi perlu dicatat sebelum evaluasi akhir.

Runner akhir menyiapkan optimizer AdamW dengan learning rate 0,001 dan weight decay 0,0001 untuk GNN. Bobot kelas dihitung dari frekuensi label train. Batch berukuran delapan digunakan dengan batas 100 epoch dan penghentian ketika validation loss tidak membaik selama 15 epoch. Random seed 42 ditetapkan untuk membantu reproduksibilitas. Parameter ini adalah konfigurasi awal eksperimen yang tersedia; perubahan maupun pencarian parameter tambahan harus dicatat dan tidak dipilih berdasarkan hasil test.

Pembagian data dan prosedur evaluasi

Pembagian dilakukan menurut pertandingan: J03WMX, J03WN1, J03WOH, J03WOY, dan J03WR9 sebagai train; J03WQQ sebagai validation; serta J03WPY sebagai test. Dengan cara ini, episode dari pertandingan yang sama tidak berada pada split berbeda. Kandidat, label, dan identitas split dibuat konsisten untuk ketiga model. Imputasi dan normalisasi dipelajari dari train. Ambang keputusan tiap model dipilih menggunakan F1 pada validation, lalu digunakan pada test tanpa pemilihan ulang berdasarkan hasil test.

Tabel 4 Pembagian pertandingan dalam eksperimen

Split	Pertandingan	Peran
Train	J03WMX, J03WN1, J03WOH, J03WOY, J03WR9	Mempelajari parameter model dan statistik preprocessing
Validation	J03WQQ	Memilih checkpoint GNN dan ambang klasifikasi
Test	J03WPY	Menilai konfigurasi model setelah keputusan pengembangan dikunci

Kesetaraan kandidat diperiksa melalui identitas episode sebelum prediksi digabungkan untuk evaluasi. Penggunaan satu pertandingan pada validation dan satu pada test membatasi jumlah kondisi yang terwakili. Metrik harus disertai jumlah sampel serta komposisi kelas. Hasil pilot yang sudah digunakan untuk memeriksa integrasi juga perlu dicatat dalam riwayat pengembangan, sehingga artefak tersebut tidak diperlakukan sebagai evaluasi final yang independen.

Evaluasi direncanakan menggunakan precision, recall, F1, ROC-AUC, average precision (AP), serta confusion matrix. Precision adalah TP/(TP + FP), recall adalah TP/(TP + FN), dan F1 adalah 2 × precision × recall/(precision + recall). AP merangkum hubungan precision–recall pada berbagai ambang. Implementasi saat ini menyimpan AP dalam kolom bernama pr_auc; artikel menggunakan istilah AP agar tidak menyamakannya dengan integrasi trapezoidal kurva precision–recall. Hasil perlu ditafsirkan bersama jumlah sampel dan distribusi kelas.

True positive menyatakan episode gegenpressing yang terdeteksi positif, false positive menyatakan episode negatif yang diprediksi positif, dan false negative menyatakan episode gegenpressing yang terlewat. Confusion matrix mempertahankan jumlah kesalahan pada kedua kelas agar nilai agregat dapat dijelaskan. ROC-AUC dan AP memanfaatkan skor probabilitas pada berbagai ambang, sedangkan precision, recall, dan F1 dilaporkan pada ambang yang dipilih dari validation. Jika sampel sangat sedikit atau salah satu kelas tidak tersedia, interpretasi metrik harus dibatasi dan kondisi tersebut dilaporkan.

Runner membatasi pelatihan final hingga seluruh antrean anotasi diisi, identitas kandidat dan label valid, serta setiap split memiliki sekurang-kurangnya lima contoh untuk masing-masing kelas. Batas lima merupakan pengaman operasional pipeline, bukan pembuktian kecukupan statistik. Snapshot anotasi, konfigurasi, prediksi, dan checksum direncanakan disimpan sebagai artefak reproduksibilitas. Pada progres saat ini, syarat pelatihan akhir belum terpenuhi.

Reproduksibilitas dan penguatan eksperimen

Artefak eksperimen akhir direncanakan memuat salinan anotasi yang dibekukan, manifest split, fitur atau graph cache yang digunakan, konfigurasi model, bobot terlatih, riwayat pelatihan, probabilitas prediksi, dan checksum input. Snapshot ini diperlukan karena anotasi dan manifest dapat berubah selama penelitian. Pembaruan label harus menghasilkan perhitungan ulang jumlah sampel, sehingga statistik lama tidak digunakan untuk mendeskripsikan dataset terbaru.

Penguatan eksperimen yang belum dilaksanakan meliputi peninjauan label oleh penilai kedua, penyelarasan ruang jarak graph dengan dimensi lapangan, serta pembandingan input pada window yang sama. Ablasi GCN tanpa GRU dapat digunakan untuk menilai kebutuhan komponen temporal, sedangkan evaluasi pada beberapa pemisahan pertandingan dapat menilai sensitivitas terhadap laga test. Hasil pengujian tambahan baru dapat dimasukkan sebagai temuan setelah prosedur, data, dan keluaran eksperimennya tersedia.

Rujukan bagian ini

[1] M. Bassek, R. Rein, H. Weber, dan D. Memmert, “An integrated dataset of spatiotemporal and event data in elite soccer,” Scientific Data, vol. 12, artikel 195, 2025. https://doi.org/10.1038/s41597-025-04505-y

[2] M. Bassek, R. Rein, H. Weber, dan D. Memmert, “An integrated dataset of spatiotemporal and event data in elite soccer,” Figshare, dataset, versi 1, 2025. https://doi.org/10.6084/m9.figshare.28196177.v1

[4] T. N. Kipf dan M. Welling, “Semi-supervised classification with graph convolutional networks,” International Conference on Learning Representations, 2017. https://arxiv.org/abs/1609.02907

[5] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, dan Y. Bengio, “Learning phrase representations using RNN encoder–decoder for statistical machine translation,” Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing, hlm. 1724–1734, 2014. https://doi.org/10.3115/v1/D14-1179

[6] T. Chen dan C. Guestrin, “XGBoost: A scalable tree boosting system,” Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, hlm. 785–794, 2016. https://doi.org/10.1145/2939672.2939785

[7] F. Pedregosa et al., “Scikit-learn: Machine learning in Python,” Journal of Machine Learning Research, vol. 12, hlm. 2825–2830, 2011. https://www.jmlr.org/papers/v12/pedregosa11a.html